مشروع معالجة اللغات الطبيعية

اللهجات العربية على المستوى الإقليمي والقطري التعرف على

باستخدام تقنيات التعلم الآلي

إعداد الطالب: Younes Limane

السنة الدراسية: 2026

تقرير مشروع NLP

الملخص

Streamlit لإدخال النص وعرض النتيجة. ركزت النسخة الحالية على المنطقة والدولة، وتأجل تصنيف المدينة إلى عمل مستقبلي. المنطقة أولا ثم الدولة داخل المنطقة. حقق LinearSVC أفضل أداء إقليمي بدقة 87.57% وMacro-F1 بلغت 81.93%. كما طورت واجهة التسميات وإزالة التكرار. استخدم تمثيل Character TF-IDF مع نموذجي Logistic Regression وLinearSVC، ثم بني نظام هرمي يحدد للتعرف على اللهجات العربية المكتوبة على مستويين: المنطقة والدولة. تم دمج بيانات IADD وMADAR بعد تنظيف النصوص وتوحيد يهدف هذا المشروع إلى بناء نظام آلي

Abstract

This project presents a hierarchical system for identifying written Arabic dialects at the regional and country levels. IADD and MADAR corpora were cleaned, normalized, deduplicated, and split into training, validation, and test sets. Character TF-IDF was combined with Logistic Regression and LinearSVC classifiers. The system first predicts the region and then the country using a region-specific classifier. LinearSVC achieved 87.57% accuracy and 81.93% macro-F1 for regional classification. A Streamlit interface was developed for interactive testing. City-level classification is left for future work.

الكلمات المفتاحية: معالجة اللغات الطبيعية، اللهجات العربية، LinearSVC، TF-IDF، MADAR، IADD.

المقدمة العامة

مساهمات المشروع في دمج مصادر مختلفة، وبناء نماذج أساسية قابلة للتشغيل، وتصميم تصنيف هرمي، وتوفير واجهة استخدام. مشكلة المشروع في تحديد اللهجة من نص عربي مكتوب، مع تقسيم المهمة إلى مرحلتين: تحديد المنطقة ثم تحديد الدولة. تتمثل لذلك فإن التعامل مع كل النصوص العربية على أنها فصحى أو لهجة واحدة يحد من دقة تطبيقات معالجة اللغات الطبيعية. تتمثل تتميز اللغة العربية بتعدد لهجاتها واختلاف مفرداتها وتراكيبها حسب الموقع الجغرافي.

محتويات التقرير

يتناول التقرير حالة الفن، ومصادر البيانات ومعالجتها، وتصميم النظام وتنفيذه، ثم التجارب والنتائج والخاتمة والمراجع.

الفصل الأول: حالة الفن

على Character n-grams، مع فصل المشكلة إلى مستوى إقليمي ثم قطري. يسمح هذا التصميم بإضافة مستوى المدينة مستقبلا. بينما تستخدم أعمال أخرى بيانات مدينية أو نماذج Transformer عربية. يتميز هذا المشروع ببناء حل عملي منخفض التكلفة يعتمد مهمة التعرف على اللهجات العربية باستخدام نماذج التعلم الآلي والتعلم العميق. تعتمد بعض الأنظمة على التصنيف المباشر للدولة، تناولت أعمال سابقة

الفصل الثاني: تحليل البيانات

تم اختيار المصادر التالية وفق طبيعة التسميات وتوفر النصوص:

الملاحظة	الاستخدام	المصدر
نصوص عربية مع تسميات لهجية	التدريب	IADD
بيانات مرتبطة بمدن عربية	التدريب	MADAR
النسخة المتاحة TEST فقط	لم يستخدم في التدريب	NADI
بيانات التدريب تعتمد على Twitter IDs	اختبار خارجي	QADI

بعد المعالجة وإزالة التكرار أصبحت البيانات كما يلي:

القيمة	المؤشر
247,804	السجلات الخام
247,803	بعد المعالجة
238,274	بعد إزالة التكرار
127,125	IADD
111,149	MADAR

البيانات إلى Train = 166,796، وValidation = 35,739، وTest = 35,739. لم تستخدم سجلات Unknown في تدريب نموذج الدولة. تم تقسيم

المعالجة النصية

التطويل العربي، ومحارف التحكم، وتوحيد بعض الحروف العربية، وتوحيد الفراغات، ثم توحيد أسماء المناطق والدول وإزالة التكرار.
لذلك حولت السجلات إلى صيغة موحدة تحتوي على: source، city، country، region، text. شملت المعالجة إزالة الروابط، والتشكيل، تختلف بنية ملفات المصادر،

الكتابية داخل الكلمات ويتناسب مع الاختلافات الإملائية واللهجية. كما لم تختلق تسميات للمدن عند عدم توفرها في المصدر.
يتم استخدام Lemmatization أو Stopword Removal؛ لأن المصنف يعتمد على Character-level TF-IDF الذي يحافظ على المؤشرات لم

تصميم النظام

التدفق العام للنظام هو:

العملية	المرحلة
IADD + MADAR	1
تنظيف وتطبيع النصوص	2
توحيد التسميات وإزالة التكرار	3
تقسيم Train / Validation / Test	4
Character TF-IDF	5
لتحديد المنطقة LinearSVC	6
مصنف الدولة الخاص بالمنطقة	7
واجهة Streamlit	8

الاختيارات التقنية

بسبب أدائه الجيد في التصنيف النصي عالي الأبعاد. أما التصنيف الهرمي فيقلل صعوبة التمييز بين عدد كبير من الدول دفعة واحدة.
اختير Character TF-IDF لأنه لا يتطلب محللا صرفيا، ويلتقط أجزاء الكلمات والأنماط الإملائية المميزة للهجات. استخدم LinearSVC

الفصل الرابع: التنفيذ

التالية: matplotlib، joblib، scikit-learn، وStreamlit. أديرت الشفرة باستخدام Git، وحفظت النماذج والنتائج في مجلدات مستقلة. تم تنفيذ المشروع باستخدام Python 3.13 والمكتبات

الوظيفة	الملف
قراءة وتنظيف ودمج وتقسيم البيانات	prepare_data.py
تدريب Logistic Regression وLinearSVC	train_baselines.py
تدريب نماذج الدول حسب المنطقة	train_hierarchical.py
تنفيذ التنبؤ الهرمي لنص واحد	predict.py
واجهة Streamlit التفاعلية	app.py

التدريب وحفظ النماذج

أقصى 300,000 ميزة. حفظت vectorizers والمصنفات بصيغة joblib، كما حفظت المقاييس ومصفوفات الالتباس بصيغة JSON وPNG. على مستوى المنطقة والدولة: Logistic Regression وLinearSVC. استخدم Character TF-IDF بمدى n-grams من 3 إلى 5 وبحد درب نموذجان أساسيان

الصعوبات والحلول

استخدام TEST للتدريب، وحفظ QADI المتاح كاختبار خارجي. كما استخدم التصنيف الهرمي لتقليل الالتباس بين اللهجات المتقاربة. ونقص بيانات التدريب في NADI، واعتماد QADI على معرفات Twitter بدل النصوص. عولجت هذه المشكلات بإنشاء قارئ موحد، وعدم تمثلت الصعوبات في اختلاف تنسيقات الملفات،

واجهة الاستخدام

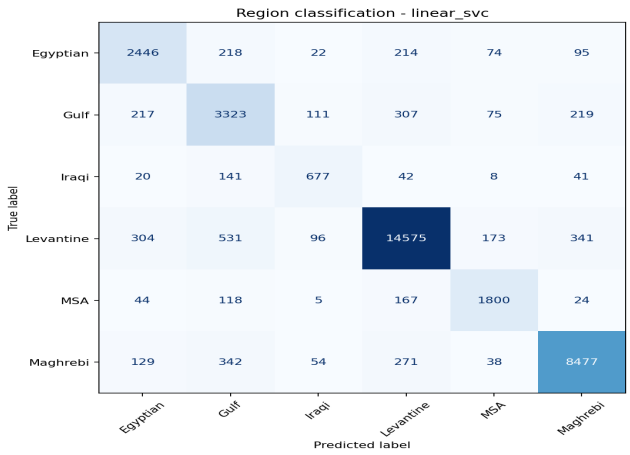
أثناء المعالجة، وتقدم اسم المنطقة بالعربية واسم الدولة مع صورة العلم. الواجهة الحالية مخصصة للمنطقة والدولة، ولا تعرض المدينة. تسمح الواجهة للمستخدم بإدخال نص عربي، ثم تعرض شريط تقدم

الفصل الخامس: التجارب والنتائج

اعتمد التقييم على Accuracy وPrecision وRecall وMacro-F1 وWeighted-F1، مع استخدام مجموعة الاختبار التي لم تدخل في تدريب المصنف.

المهمة	النموذج	Accuracy	Macro-F1
Region	Logistic Regression	83.54%	76.58%
Region	LinearSVC	87.57%	81.93%
Country	Logistic Regression	74.68%	63.97%
Country	LinearSVC	78.77%	67.92%

تستخدم المصرية والعراقية تعيينا ثابتا لأن كل منطقة تحتوي على دولة واحدة في البيانات المستخدمة. Macro-F1 = 63.67% وGulf Accuracy = 91.08% وMaghrebi Macro-F1 = 76.42% وLevantine Accuracy = 74.32%، وMacro-F1 = 88.43%، وAccuracy = 81.14% في التصنيف الهرمي بلغت النتائج:



الشكل 1: مصفوفة الالتباس لتصنيف المنطقة باستخدام LinearSVC.

مناقشة النتائج والقيود

المنطقة ينتقل إلى المرحلة الثانية في النظام الهرمي. لذلك ينبغي تفسير الناتج كتنبؤ احتمالي، خصوصا مع النصوص القصيرة جدا. Logistic في المهمتين. يرجع انخفاض أداء الدولة إلى تشابه اللهجات داخل المنطقة وعدم توازن عدد الأمثلة. كما أن خطأ تحديد تفوق LinearSVC على Regression

الخاتمة والآفاق

تم بناء نظام عملي للتعرف على اللهجات العربية على مستوى المنطقة والدولة. دمج النظام بيانات IADD وMADAR، وطبق تنظيفا وتوحيدا للتسميات، ثم استخدم Character TF-IDF مع LinearSVC داخل بنية هرمية. حقق النظام Accuracy %87.57 على مستوى المنطقة، كما أنشئت واجهة Streamlit قابلة للتجربة. لم يفعل تصنيف المدينة في النسخة الحالية.

تشمل التحسينات المستقبلية إضافة بيانات NADI وQADI عند توفر نصوص تدريب مرخصة، وتجربة AraBERT أو CAMeL-BERT، ومعالجة عدم توازن الفئات، وتفعيل تصنيف المدينة، ونشر الواجهة كخدمة ويب أو API، مع مراعاة الخصوصية وحقوق استخدام البيانات.

المراجع

1. IADD Dataset, Hugging Face: https://huggingface.co/datasets/evageon/IADD

2. MADAR Corpus: https://camel.abudhabi.nyu.edu/madar-parallel-corpus/

3. NADI Shared Task: https://github.com/UBC-NLP/nadi

4. QADI Dataset: https://github.com/qcri/QADI

5. Scikit-learn Documentation: https://scikit-learn.org/

6. Streamlit Documentation: https://docs.streamlit.io/

الملحق: مثال تشغيل

الأمر: python scripts\predict.py --text "شو أخبارك اليوم؟"

الناتج المتوقع تقريبا: المنطقة الشامية، والدولة لبنان. النتائج تقديرية وقد تختلف للنصوص القصيرة أو المتشابهة.

ملاحظة التسليم

يرفق هذا التقرير باسم Report_YOUNES_LIMANE.pdf مع ملف المصدر المضغوط Source_YOUNES_LIMANE.zip عبر نموذج الأستاذ قبل 1 ديسمبر 2026.